

FAIO 2024 Problem Statements

А Результаты теста по математике

Автор: Adil Toktaganov

В классе из 30 учеников провели тест по математике. Результаты распределились следующим образом:

- Средний балл (среднее арифметическое) теста составил — 75.
- Медианный балл теста — 78.
- Стандартное отклонение баллов — 5.

Позже к результатам добавили ещё двух учеников, каждый из которых получил 90 баллов. На основе новой информации ответьте на следующие вопросы:

1. Какой стал новый средний балл? Введите число с точностью до двух знаков после запятой.
2. После добавления двух учеников медианный балл теста остался равным 78. Учитель объявил, что любой ученик, чей балл превышает медианный на величину нового стандартного отклонения, получит особую похвалу. Дархан, который изначально получил 78 баллов, хочет получить эту похвалу. Ему разрешено пересдать тест один раз, чтобы улучшить свой результат. Какой минимальный балл должен получить Дархан при пересдаче, чтобы получить похвалу? Введите целое число.

Стандартное отклонение — это мера разброса данных относительно их среднего значения. Оно показывает, насколько элементы набора данных отклоняются от среднего значения в среднем.

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

- σ — стандартное отклонение, мера разброса данных относительно их среднего значения.
- N — общее количество элементов в наборе данных.
- x_i — i -й элемент набора данных.
- μ — среднее значение набора данных.

Медиана — это значение, которое делит упорядоченный набор данных на две равные части: половина значений меньше или равна медиане, а другая половина больше или равна ей.

Формат вывода Введите ответы через пробел. Например: 23.21 45


В История одного метеоролога

Автор: Magaiiya Zhussip

Старший метеоролог Адильхан работает в Казгидромете в Алматы. Он часто отправляет своего стажёра Дархана на метеостанцию Т1-Туюксу для измерения чистоты льда. Метеостанция Т1-Туюксу расположена далеко от города и добираться туда занимает около 2 часов. Из-за этого Дархан не любил ездить туда и иногда просто брал лёд из своего холодильника и записывал чистоту этого льда как показатель метеорологической станции. Это продолжалось на протяжении последних 12 месяцев. Однажды Адильхан заметил необычное значение чистоты льда в данных, предоставленных Дарханом. Когда Адильхан узнал об обмане, он уволил Дархана. Чтобы не потерять данные за прошедший год, Адильхан хочет выявить и удалить выбросы из набора данных. Поскольку он не разбирается в математике, он просит вас разработать алгоритм обнаружения выбросов.

Обнаружение выбросов (outlier detection) — это процесс идентификации данных, которые значительно отличаются от других наблюдений в наборе данных. Выбросы могут возникать по различным причинам, включая ошибки измерений, необычные события или мошеннические действия. Обнаружение выбросов является критически важной задачей, так как выбросы могут искажать статистические анализы и нарушать работу моделей машинного обучения. Их идентификация и удаление помогает повысить качество модели и точность предсказаний. Некоторые из популярных методов обнаружения выбросов включают:

- Метод межквартильного размаха (IQR). IQR вычисляется как разность между 75-м (Q3) и 25-м (Q1) перцентилями данных. Q1 — это точка данных, расположенная ровно посередине нижней половины набора данных. Q3 — это точка на полпути от медианы до конца набора данных. Наблюдения, которые выходят за пределы $Q1 - 1.5 \times IQR$ и $Q3 + 1.5 \times IQR$, считаются выбросами.
- Метод Z-оценки. В этот метод используется для данных, которые следуют нормальному распределению. Выбросы определяются как наблюдения, которые отклоняются от среднего значения более чем на определенное количество стандартных отклонений (обычно 2-3 стандартных отклонения).



Ваша задача реализовать алгоритм межквартильного размаха и вывести список выбросов одной строкой.

Входной формат Строчка содержит N значений чистоты льда разделенные пробелом:

1.5 5 7.9 100000 -250999.67

Выходной формат Строчка с K значениями выбросов разделенные пробелом:

100000 -250999.67

С Радиоактивный распад


Автор: Darkhan Nurlybai

Введение

В физике известно, что радиоактивные вещества теряют половину своей активности или массы за каждые T_0 секунд, что описывается следующим уравнением:

$$m(t) = m_0 \left(\frac{1}{2} \right)^{t/T_0}$$


Вам предоставлены результаты эксперимента в виде n пар значений t и $m(t)$. Ваша задача заключается в том, чтобы определить период полураспада T_0 .



Для этой задачи вы можете использовать различные эвристические методы или классический метод линейной регрессии, предварительно преобразовав данные для удобства.

Линейная регрессия

Давайте рассмотрим набор данных $\{(x_i, y_i)\}_{i=0}^n$, который обладает линейной зависимостью. Мы можем смоделировать эту связь, используя линейную функцию $f(x) = ax + b$, где a и b представляют собой параметры модели, описывающие угловой коэффициент и смещение соответственно.



Параметры итоговой линейной функции могут быть определены посредством минимизации среднеквадратичного отклонения каждой точки от прямой:

$$L(a, b) = \frac{1}{n} \sum_{i=0}^n (f(x_i) - y_i)^2 = \frac{1}{n} \sum_{i=0}^n (ax_i + b - y_i)^2 \rightarrow \min$$

Решая уравнения $\frac{\partial}{\partial a} L(a, b) = 0$ and $\frac{\partial}{\partial b} L(a, b) = 0$, можно аналитически определить значения a и b

Критерий оценки

Если ваше предсказание окажется в пределах 1% от правильного ответа, вы получите 100 баллов. В противном случае, результат будет равен 0. Итоговый балл будет рассчитываться как среднее значение баллов за все тестовые наборы.

Формат ввода

n n : количество измерений.
 $m_1\ t_1$ m_i : масса радиоактивного элемента (вещественное число)
 $m_2\ t_2$ в момент времени t_i (вещественное число).

...
 $m_n\ t_n$

Ограничения

$1 < n \leq 1000$
 $1 < m_i \leq 10000$
 $1 \leq t_i \leq 5000$

Пример ввода

5
1000 0
500 10
250 20
125 30
62.5 40.0

В этом примере:

Есть 5 измерений. Начальная масса равна 1000. Период полураспада составляет 10 секунд.

Формат вывода

T_0

Пример вывода

10.01

Подсказка

В решении этой задачи может оказаться полезным использовать натуральный логарифм.

```
from math import log
```

D Kmeans


Автор: Darkhan Nurlybai

Введение


Кластеризация — это задача группировки набора объектов таким образом, чтобы объекты в одной группе (называемой кластером) были более похожи друг на друга, чем на объекты в других группах (кластерах). Кластеризация используется во многих областях, например:

- Поиск информации: Чтобы находить похожие документы или веб-страницы.
- Биоинформатика: Чтобы группировать гены или белки по их функциям.
- Обнаружение аномалий: Она помогает найти данные, которые не вписываются в общую картину.

Рассмотрим простой пример кластеризации, чтобы наглядно продемонстрировать работу алгоритма на двумерных данных:



Тут показан пример, как точки разбиваются на два кластера.



Kmeans

Мы можем формализовать эту задачу. Допустим, мы хотим найти k кластеров $(S_1, \dots, S_k)$, таких, что минимизируется следующая целевая функция:

$$L = \frac{1}{n} \sum_{j=1}^k \sum_{\vec{r}_i \in S_j} |\vec{r}_i - \vec{\mu}_j|^2$$

где,

$$\vec{\mu}_j = \frac{1}{|S_j|} \sum_{\vec{r} \in S_j} \vec{r}$$

Поиск оптимального решения задачи кластеризации K-means для наблюдений в d измерениях является:


1. NP-трудной задачей в общем евклидовом пространстве (размерности d) даже для двух кластеров.
2. NP-трудной задачей для общего числа кластеров k даже на плоскости.
3. при фиксированных k и d (размерности) задача может быть точно решена за время $O(nd^{k+1})$, где n - число объектов, которые необходимо кластеризовать.

На практике для кластеризации используют следующий итеративный алгоритм:


1. Случайно выберем k центроида (центроид – центр кластера).
2. Для каждой точки найдем ближайший центроид и отнесем точку к соответствующему кластеру.
3. Для каждого кластера найдем среднюю точку и назначим ее новым центроидом.
4. Повторяем шаги 2 и 3 до сходимости.

Пример:


Начальный шаг: случайно выберем 2 центроида.



Первая итерация шагов 2 и 3:



Вторая итерация шагов 2 и 3:



Метрика

В качестве базового решения мы можем решить эту проблему для $k = 1$. В этом случае оптимальное положение кластера будет средним положением всех точек. Назовем значение функции потерь в этом случае $L_{baseline}$.

Чтобы оценить, насколько хорошо работает наша модель, мы можем использовать следующую формулу. Она дает нам значение от 0 до 1, где 1 — это идеальный результат:

$$m = \begin{cases} 0 & \text{если } L \geq L_{baseline} \\ 1 - L/L_{baseline} & \text{иначе} \end{cases}$$

Ваша задача — реализовать алгоритм K-means. Для исключения влияния случайности, обусловленного выбором начальных центроидов, вам будут предоставлены заранее определенные координаты точек данных и начальные положения центроидов.

Вы получите 100 баллов, если метрика вашей модели не меньше, чем метрики нашей модели умноженное на 0.95, в противном случае вы получите 0.

Итоговый балл будет средним баллом по всем тестовым наборам.

Формат ввода

n
 $x_1 y_1$
 $x_2 x_2$
...
 $x_n y_n$
 k
 $cx_1 cy_1$
...
 $cx_k cy_k$

Описание

n - число точек.
 x_i, y_i - координаты i -й точки.
 k - количество центроидов.
 cx_i, cy_i - координаты i -го центроида.

Ограничения

$1 < n < 1000$
 $1 < k < 10$
 $1 < x_i, y_i, cx_i, cy_i < 50$

Пример ввода

5
-1 1
-1 2
-2 1
1 0
2 0
2
-2 2
3 0

Формат вывода

$cx_1 cy_1$
...
 $cx_k cy_k$

Пример вывода

1.5 0
-1.5 1.3

Описание

Финальные позиции ваших центроидов после применения алгоритма K-means.

Е Классификация статей

Автор: Beksultan Sagyndyk

Старший метеоролог Адильхан работает в Казгидромете в Алматы и всегда стремится оставаться в авангарде научных достижений. Он следит за последними открытиями в области метеорологии и делится интересными статьями со своими коллегами. Однажды Адильхан поручил своему стажеру Дархану важное задание: проанализировать научные статьи и новости для метеорологической службы.

Однако Дархан, помимо своей любви к метеорологии, был заядлым читателем журнала Medium. Он часами читал, но вместо статей о климате присылал материалы о футболе, космосе и роботах. Адильхан был шокирован, когда на его столе оказались тексты о чемпионатах мира по футболу и космических полетах.

Поразмыслив, Адильхан понял, что Дархан просто не знает, как правильно классифицировать статьи. Поэтому он решил помочь своему стажеру и придумать способ эффективной сортировки текстов с использованием ключевых слов, которые четко указывали бы на тему статьи.

Классификация текстов с помощью ключевых слов — важная часть современных диалоговых систем (чат-боты, ассистенты, агенты), которые зачастую работают на основе LLM. Данный метод позволяет точно и надежно определять намерения пользователя и корректно направлять его по соответствующей схеме внутри диалога. Необходимо создать алгоритм, который на основе ключевых слов из датасета статей на Medium сможет корректно сопоставить тексту соответствующий Tag. Основной датасет, который нужен для этого, расположен по следующей ссылке: `train_set.csv`.

В нем около 50 000 примеров и 95 уникальных классов/Tags. Датасет в формате csv, колонки разделены при помощи символа “\t”, то есть четырьмя пробелами или Tab.

Текст — это заголовок и подзаголовок статьи.

Ter (Tag) — это метка или класс текста.

Ключевые слова — набор слов, извлеченных из множества текстов, относящихся к определенному теру (например, для тега «football» ключевые слова: ‘Football’, ‘league of champions’, ‘cristiano’, ‘Cristiano Ronaldo’, ‘cr7’, ‘world cup’, ‘Ballon d’Or’).

Метрика или правило по которому будет выставляться балл: доля (%) правильно угаданных классов/Tags из скрытого датасета.

Пример:

Текст — Brazil win the World Cup for the fifth time in Japan and South Korea.

Тег — football

Общий алгоритм действий:

1. Анализируем тексты из датасета и токенизируем их (разделяем по пробелу, на n-граммы и т. д., на ваш выбор). Таким образом переводим текст в набор ключевых слов/фраз/токенов.
2. Далее для каждого тега/метки создаем набор его наиболее важных и релевантных ключевых слов/фраз/токенов.
3. Создаем правило для сопоставления текста и тега путем пересечения множеств их ключевых слов (правило может быть любое: голосование большинства, наибольшее количество совпадающих слов и т. д.).
4. С помощью алгоритма из пункта 3 присваиваем каждому входному тексту из "скрытого" датасета его Tag.

Формат ввода

Каждая строка относится к отдельному тексту (Заголовок+Подзаголовок), количество текстов равно N , $1 \leq N \leq 10,000$, в формате: —————

Title: How do Transformers work? ***Subtitle***: In this section, we will take a high-level look at the architecture of Transformer models.

Title: ...

...

...

Строка N

Код для считывания (Python):

```
import sys
input_data = sys.stdin.read()
lines = input_data.splitlines()
```

Формат вывода

1 строка, каждый Tag разделен при помощи ":

"ai, football, politics, ..., N-th Tag"

Примечания

Все данные на английском языке, каждая статья имеет только один уникальный Tag.


F SVM

Автор: Darkhan Nurlybai

Введение

Часто в алгоритмах машинного обучения возникает необходимость классифицировать данные. В данной задаче необходимо реализовать **метод опорных векторов** (support vector machine — SVM), который относится к семейству линейных классификаторов.

Для простоты рассмотрим n точек на двумерной плоскости. Каждая из этих точек принадлежит одному из двух классов, обозначенных как $l_i = \pm 1$. Гарантируется, что точки можно разделить прямой так, что по одну сторону от нее будут находиться точки одного класса. Искомых прямых может быть много, поэтому будем искать такую прямую L , что сумма расстояний от нее до двух ближайших точек, лежащих по разные стороны, будет максимальна. Это способствует более уверенной классификации.




Алгоритм классификации

Пусть линия L задается уравнением $ax + by + c = 0$. Тогда линии L' и L'' , параллельные L , можно описать уравнениями $ax + by + c + \delta = 0$ и $ax + by + c - \delta = 0$ соответственно, где $\delta > 0$. Для удобства прямые L и L'' , проходящие через эти две точки, будем называть опорными векторами. Расстояние между прямыми L' и L'' :

$$H = \frac{2\delta}{|\vec{n}|} \quad (1)$$

Точку (x, y) будем классифицировать следующим образом:

$$a(x, y) = \begin{cases} +1 & \text{если } ax + by + c \geq 0, \\ -1 & \text{иначе} \end{cases}$$



Функция потерь

Алгоритм будем штрафовать при неправильной классификации:

$$f(x, y, l) = \begin{cases} 0 & \text{если } a(x, y) = l, \\ |\vec{n}| d(L, x, y) & \text{иначе} \end{cases}$$

Здесь $d(L, x, y)$ обозначает расстояние от точки с координатами (x, y) до прямой L .

Также мы ходим, чтобы зазор между опорными векторами L' и L'' был как можно большим, поэтому рассмотрим функцию потерь (гиперпараметр λ алгоритма нужно подобрать самостоятельно):

$$Loss = \lambda |\vec{n}|^2 + \frac{1}{k} \sum_{i=1}^k f(x_i, y_i, l_i) \quad (2)$$

Ваша задача найти параметры a, b, c прямой L , используя градиентный спуск который будет минимизировать $Loss$.

Метрика

В констесте будем измерять для каждого теста долю правильных ответов (точность), и итоговая метрика определяется по этой формуле:

$$score = \begin{cases} 0 & \text{если точность} < 0.97 \\ 100 \cdot \text{точность} & \text{иначе} \end{cases}$$

Итоговый балл будет средним баллом по всем тестовым наборам.

Формат ввода

k

$x_1 \ y_1 \ l_1$

$x_2 \ y_2 \ l_2$

...

$x_k \ y_k \ l_k$

Описание

k - число точек.

x_i, y_i - координаты i -ый точки

l_i - класс i -ый точки

Ограничения

$1000 < k < 4000$

$-100000 < x_i, y_i < 100000$

Пример ввода

10

2 6 -1

4 -8 1

9 -1 -1

5 2 -1

-9 7 -1

10 4 -1

2 -8 1

-6 -4 1

-10 -4 1

-2 8 -1

Формат вывода

$a \ b \ c$

Пример вывода

1 1 0